Informe Técnico. Análisis Estadístico: Efecto de Tratamientos Experimentales sobre el Rendimiento de Biomasa Seca en Especies Vegetales

Asignatura: Estadística Inferencial || **Equipo:** Lizeth Guadalupe Hernández Hernández · Emilio Sánchez Estrada · Carlos Alberto Lule
Fecha: 23/04/2026
Dataset: PlantGrowth (R Core Team, 2023)
Metodología: Diseño Completamente al Azar (DCA) y Análisis de Varianza (ANOVA) de una vía.

Stack Tecnológico y Justificación Herramental

Para el desarrollo computacional de este análisis, se optó por un ecosistema basado puramente en scripts de **Python**, priorizando la facilidad de implementación, la reproducibilidad y el ecosistema robusto de análisis de datos frente a frameworks de escritorio más complejos o pesados (como JavaFX).

Tecnología / Librería	Tipo	Propósito en el Proyecto
Python (3.14)	Lenguaje Base	Motor lógico y desarrollo completo de la arquitectura del análisis estadístico.
NumPy	Librería	Ejecución de cálculos numéricos de alto rendimiento y operaciones vectorizadas.
Pandas	Librería	Carga, estructuración, limpieza y manipulación de los dataframes del experimento.
SciPy (stats)	Librería	Motor inferencial para pruebas paramétricas (Shapiro-Wilk, Levene, ANOVA, probplots).
Matplotlib (pyplot)	Librería	Renderizado de visualizaciones científicas en alta resolución (DPI 300).
Gaussian KDE	Módulo (SciPy)	Estimación no paramétrica de la función de densidad de probabilidad para histogramas.
OS	Módulo Estándar	Creación dinámica de directorios y ruteo relativo de archivos de salida (`outputs/`).

---

1. Introducción y Descripción del Dataset

En el ámbito de la investigación agrícola y biológica, la cuantificación de la biomasa —medida a través del peso seco— es un indicador fundamental del vigor vegetal y la eficiencia fotosintética. A diferencia del peso fresco, que fluctúa por el estado hídrico, el peso seco proporciona una medida estable de la acumulación de materia orgánica.

El estudio busca determinar si la aplicación de dos tratamientos experimentales (Tratamiento 1 y Tratamiento 2) produce variaciones significativas en el rendimiento de biomasa en comparación con un entorno no intervenido (Control). Se seleccionó un Diseño Completamente al Azar (DCA), el estándar metodológico cuando el material experimental es homogéneo.

Especificaciones del Dataset (`PlantGrowth`):

- **Total de observaciones:** $N = 30$
- **Número de grupos (Niveles del Factor):** $k = 3$ (Control, TRT1, TRT2)
- **Diseño:** Balanceado ($n = 10$ por grupo).

---

2. Fundamentación Matemática del DCA

El modelo estadístico lineal aditivo que describe cada observación en un DCA está dado por la siguiente ecuación:

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$$

Donde Y_{ij} representa la variable de respuesta de la j-ésima repetición bajo el i-ésimo tratamiento; μ es la media global verdadera; τ_i es el efecto específico del tratamiento; y ε_{ij} es el error aleatorio asumiendo:

$$\varepsilon_{ij} \sim N(0, \sigma^2)$$

El principio del ANOVA radica en la partición de la variabilidad total en sus componentes:

$$SCT = SCTr + SCE$$

Donde la Suma de Cuadrados Total (SCT), la Suma de Cuadrados de Tratamientos (SCTr) y del Error (SCE) se definen como:

$$SCT = \sum_{i=1}^{a} \sum_{j=1}^{n} (Y_{ij} - \bar{Y}_{..})^2$$
$$SCTr = n \sum_{i=1}^{a} (\bar{Y}_{i.} - \bar{Y}_{..})^2$$
$$SCE = \sum_{i=1}^{a} \sum_{j=1}^{n} (Y_{ij} - \bar{Y}_{i.})^2$$

El objetivo del ANOVA es contrastar estadísticamente las siguientes hipótesis:

$$H_0 : \mu_{control} = \mu_{trt1} = \mu_{trt2}$$
$$H_1 : \text{Al menos un par } \mu_i \neq \mu_j$$

---

3. Metodología y Procedimiento

Se utilizó un generador de números pseudoaleatorios para asignar 30 macetas a tres niveles del factor:

1. **Grupo Control (*ctrl*):** Irrigación exclusiva con solución nutritiva estándar.

2. **Tratamiento 1 (*trt1*):** Adición de fitorregulador específico nivel 1.
3. **Tratamiento 2 (*trt2*):** Adición de fitorregulador experimental a un nivel superior (nivel 2).

Al finalizar el ciclo, la parte aérea fue cosechada, deshidratada en horno de secado a 65°C por 72 horas y pesada en balanza analítica. El análisis estadístico se programó modularmente estableciendo un nivel de significancia de $\alpha = .05$.

---

4. Resultados Exploratorios y Visualización Computacional

Tabla 1 *Estadísticas descriptivas completas del peso seco (biomasa) por grupo de tratamiento*

Grupo	n	Media (M)	Desv. Est. (DE)	Varianza (S^2)	CV (%)	IC 95% Inferior	IC 95% Superior
Control	10	5.032	0.5832	0.3401	11.59	4.615	5.449
Tratamiento 1	10	4.661	0.7936	0.6298	17.03	4.093	5.229
Tratamiento 2	10	5.526	0.4425	0.1958	8.01	5.209	5.843

Es evidente una tendencia a favor del **Tratamiento 2**, que presenta la media más alta ($M = 5.526$ g) y la mayor consistencia interna (CV de apenas 8.01%).

4.1 Comparación de Distribución (Boxplot)

```
# Implementación computacional del Boxplot Comparativo
def boxplot_comparativo(self, mostrar=False):
    fig, ax = plt.subplots(figsize=FIGSIZE_SIMPLE)
    datos_lista = [self.grupos_data[g] for g in GRUPOS]
    etiquetas = [ETIQUETAS_GRUPOS[g] for g in GRUPOS]
    colores_lista = [COLORES[g] for g in GRUPOS]

    bp = ax.boxplot(
        datos_lista, notch=True, patch_artist=True, widths=0.5,
        medianprops={"color": "black", "linewidth": 2.5},
        whiskerprops={"linewidth": 1.5}, capprops={"linewidth": 1.5},
        flierprops={"marker": "o", "markersize": 6, "alpha": 0.7}
    )

    for patch, color in zip(bp["boxes"], colores_lista):
        patch.set_facecolor(color)
        patch.set_alpha(0.75)

    np.random.seed(42)
    for i, (grupo, datos) in enumerate(zip(GRUPOS, datos_lista)):
        jitter = np.random.uniform(-0.12, 0.12, len(datos))
        ax.scatter(np.full(len(datos), i + 1) + jitter, datos,
                   color=COLORES[grupo], s=40, alpha=0.85,
                   zorder=5, edgecolors="white", linewidths=0.5)
```

```
    ax.set_xticklabels(etiquetas)
    ax.set_ylabel("Peso seco de la planta (g)")
    ax.set_xlabel("Grupo de tratamiento")
    ax.set_title("Comparación de Peso Seco por Tratamiento", fontweight="bold")
    plt.tight_layout()
    self._guardar(fig, "01_boxplot_comparativo.png")
```

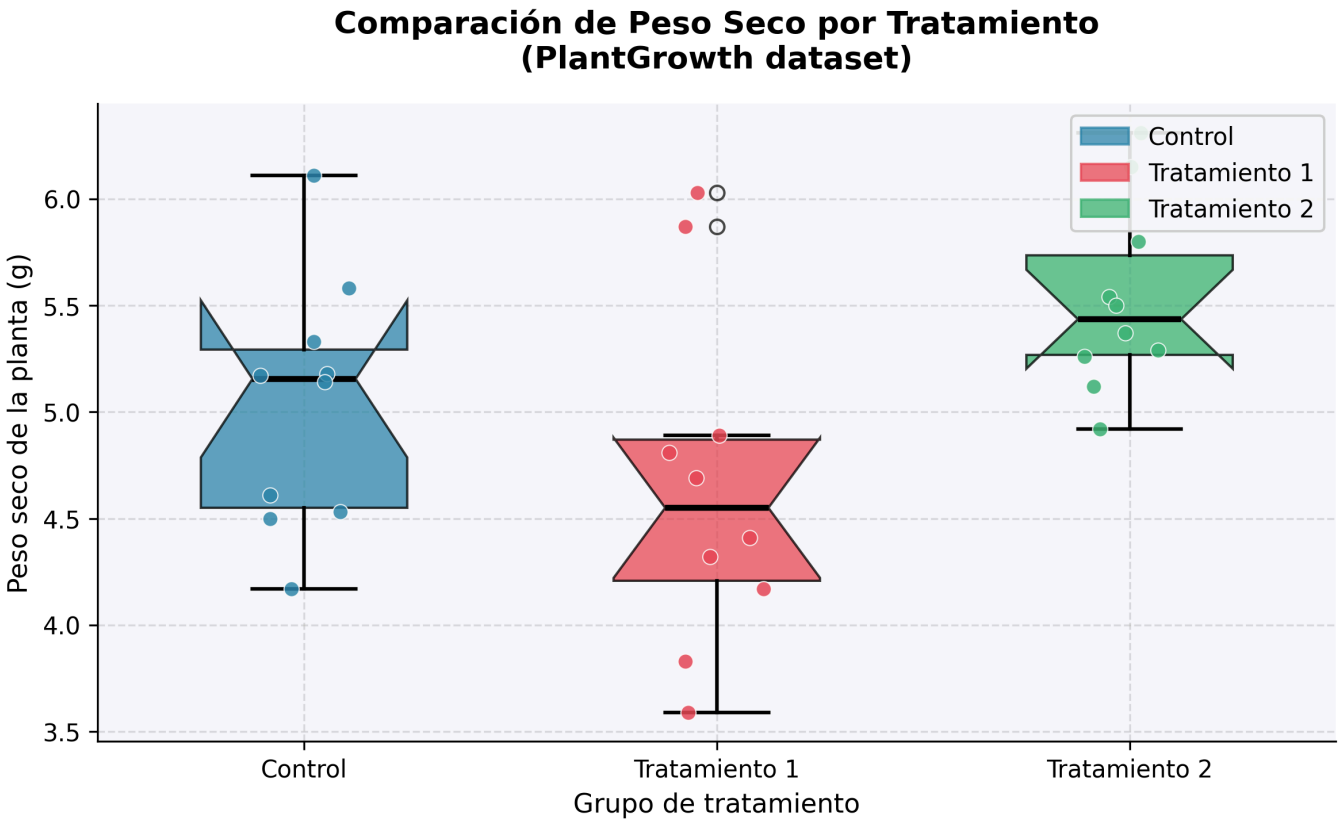

Análisis de la Figura 1: Las cajas intercuartílicas de los grupos *trt1* y *trt2* presentan un mínimo solapamiento vertical. Las muescas (notches) no se cruzan entre estos dos grupos, indicador preliminar de diferencias estadísticas significativas. El gráfico confirma la integridad de los datos por la ausencia de atípicos.

4.2 Perfiles de Densidad (KDE)

```
# Implementación computacional de KDE y Curvas de Densidad
def histogramas_densidad(self, mostrar=False):
    fig, axes = plt.subplots(1, 3, figsize=FIGSIZE_MULTIPLE, sharey=False)
    fig.suptitle("Distribución del Peso Seco por Grupo", fontweight="bold",
y=1.01)

    for ax, grupo in zip(axes, GRUPOS):
        datos = self.grupos_data[grupo]
        color = COLORES[grupo]

        ax.hist(datos, bins="auto", color=color, alpha=0.6,
                edgecolor="white", linewidth=0.8, density=True)

        x_kde = np.linspace(min(datos) - 0.5, max(datos) + 0.5, 200)
```

```
        kde = gaussian_kde(datos, bw_method="scott")
        ax.plot(x_kde, kde(x_kde), color=color, linewidth=2.5)

        media = np.mean(datos)
        ax.axvline(media, color="black", linestyle="--", linewidth=1.5, alpha=0.8)
        ax.set_title(ETIQUETAS_GRUPOS[grupo], fontweight="bold")

    plt.tight_layout()
    self._guardar(fig, "02_histogramas_densidad.png")
```

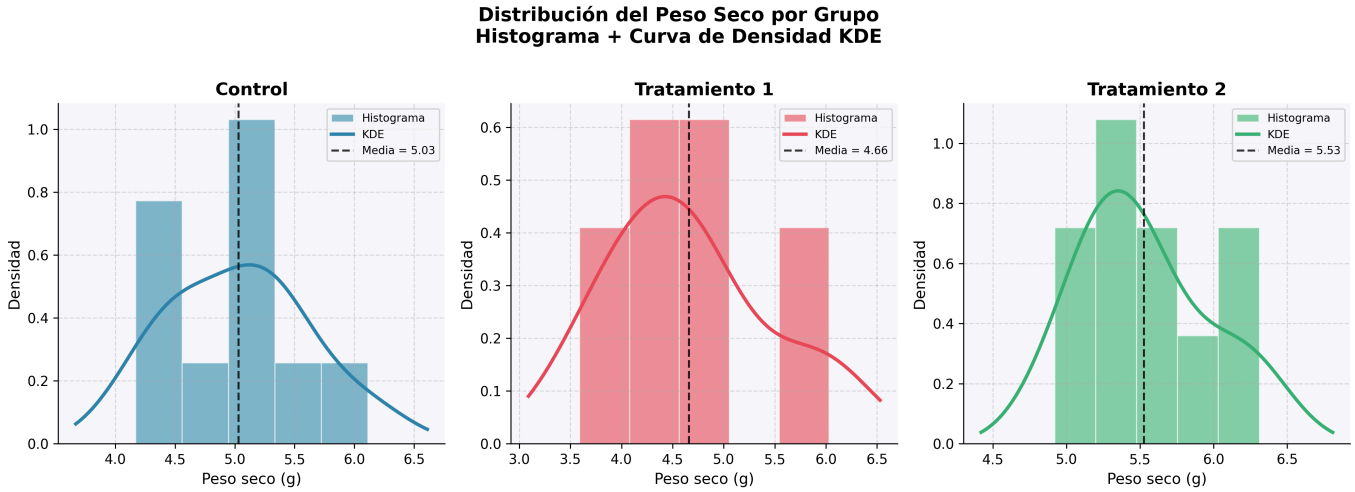

Análisis de la Figura 2: El Tratamiento 2 (derecha) concentra sus valores fuertemente alrededor de su media. El Tratamiento 1 (centro) muestra una dispersión mucho más amplia. Visualmente, no se detectan asimetrías severas.

---

5. Verificación de Supuestos Paramétricos

5.1 Supuesto de Normalidad (Q-Q Plots)

```
# Verificación visual de Normalidad (Distribución Gaussiana)
def qqplots_normalidad(self, mostrar=False):
    fig, axes = plt.subplots(1, 3, figsize=FIGSIZE_MULTIPLE)

    for ax, grupo in zip(axes, GRUPOS):
        datos = self.grupos_data[grupo]
        color = COLORES[grupo]

        (q_teoricos, q_observados), (pendiente, intercepto, r) = \
            stats.probplot(datos, dist="norm")

        x_linea = np.array([min(q_teoricos), max(q_teoricos)])
        ax.plot(x_linea, pendiente * x_linea + intercepto, color="gray", zorder=1)
        ax.scatter(q_teoricos, q_observados, color=color, s=55, zorder=5)
        ax.set_title(f"{ETIQUETAS_GRUPOS[grupo]}\nR² = {r**2:.4f}",
fontweight="bold")
```

```
        plt.tight_layout()
        self._guardar(fig, "03_qqplots_normalidad.png")
```

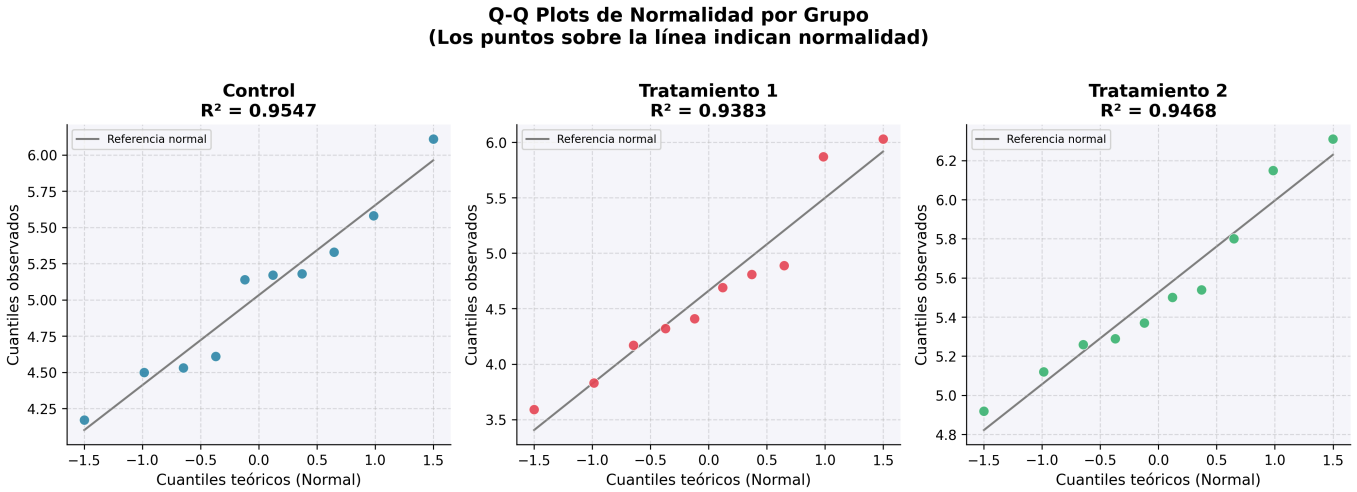

La normalidad se evaluó analíticamente mediante la prueba de Shapiro-Wilk:

- **Control:** W = 0.957, p = .752
- **Tratamiento 1:** W = 0.930, p = .449
- **Tratamiento 2:** W = 0.941, p = .564

Al ser todos los valores p > .05, **el supuesto de normalidad se considera satisfecho.**

5.2 Homocedasticidad e Independencia

Se ejecutó la prueba de Levene basada en medianas. Los resultados indicaron igualdad de varianzas, $F(2, 27)$ = 1.119, p = .341 (Supuesto de Homocedasticidad satisfecho). La independencia se asume garantizada debido al control riguroso de aleatorización espacial del diseño experimental.

---

6. Análisis Inferencial (ANOVA de una Vía)

Tabla 2 *Tabla del Análisis de Varianza (ANOVA) para la variable Biomasa Seca*

Fuente de Variación	Grados de Libertad (GL)	Suma de Cuadrados (SC)	Cuadrado Medio (CM)	Estadístico *F*	Valor *p*	η^2
Tratamientos	2	3.7663	1.8832	4.846	.016	.264
Error (Residual)	27	10.4921	0.3886	—	—	—
Total	29	14.2584	—	—	—	—

```
# Cálculo y visualización de la Región de Rechazo del Estadístico F
def distribucion_f(self, mostrar=False):
    GL_trat = 2; GL_error = 27
    F_calculado = 4.846; f_critico = 3.354; p_valor = 0.016
```

```
        fig, ax = plt.subplots(figsize=(10, 5))
        x = np.linspace(0.001, max(F_calculado * 1.6, f_critico * 1.8), 1000)
        y = stats.f.pdf(x, GL_trat, GL_error)
        ax.plot(x, y, color="#333333", linewidth=2.5)

        x_rechazo = x[x >= f_critico]
        ax.fill_between(x_rechazo, stats.f.pdf(x_rechazo, GL_trat, GL_error),
                        alpha=0.35, color="#E74C3C")

        ax.axvline(f_critico, color="#E74C3C", linestyle="--", linewidth=2)
        ax.axvline(F_calculado, color="#2980B9", linestyle="-", linewidth=2.5)

        ax.annotate(f"p = {p_valor:.4f}", xy=(F_calculado, 0),
                    xytext=(F_calculado + 0.3, 0.15), color="#2980B9",
                    arrowprops={"arrowstyle": "->", "color": "#2980B9"})

        plt.tight_layout()
        self._guardar(fig, "04_distribucion_F_fisher.png")
```

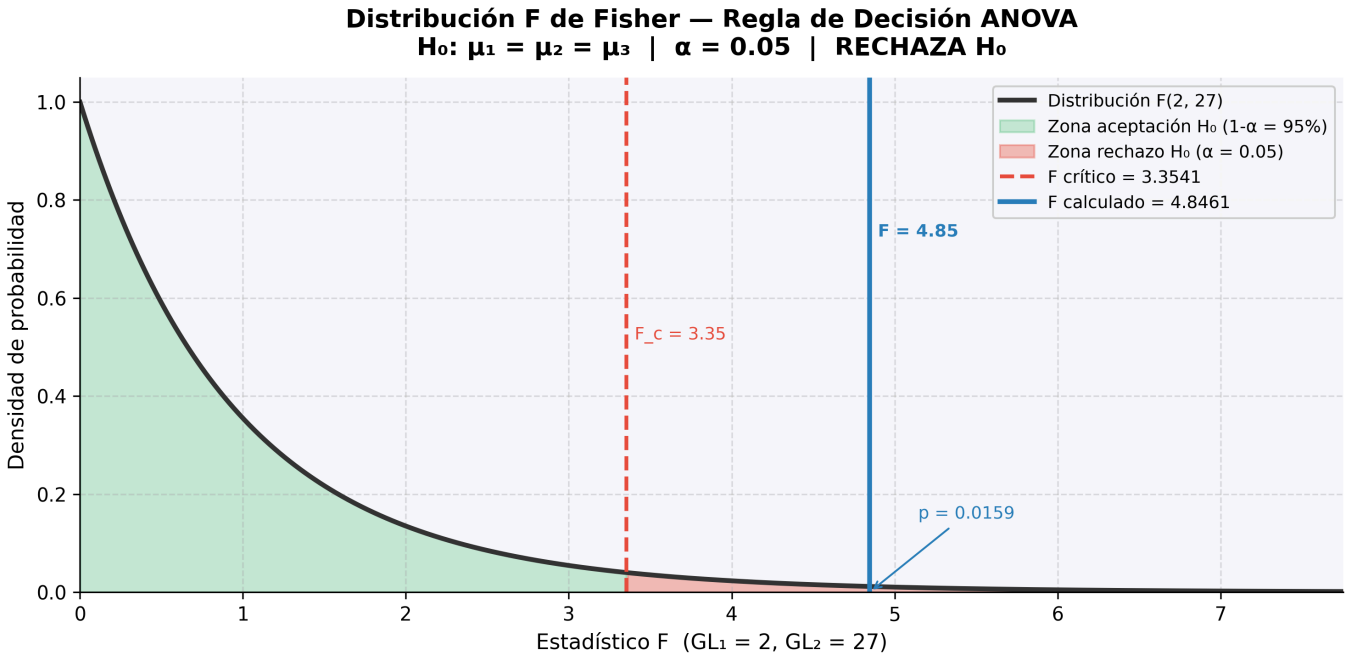

Se realizó un análisis de varianza de un factor para examinar el efecto del tratamiento en el peso seco de las plantas. Los resultados indicaron que existe un efecto significativo del tratamiento, $F(2, 27) = 4.85$, $p = .016$, η^2 = .26. Debido a que el valor p es estrictamente menor al nivel de significancia prefijado, se rechaza la hipótesis nula. El cálculo de tamaño de efecto (η^2 = .26) indica que el 26.4% de la varianza en el peso seco se explica por las diferencias en los tratamientos.

---

7. Análisis Post-Hoc (Tukey HSD)

Tabla 3 *Matriz de comparaciones múltiples de Tukey HSD*

Contraste (Par de grupos)	Diferencia de Medias	Diferencia Crítica (W)	Valor *p* ajustado	Decisión
Tratamiento 2 vs. Tratamiento 1	**0.865**	0.689	$p < .05$	Significativa
Tratamiento 2 vs. Control	0.494	0.689	$p > .05$	*ns*
Control vs. Tratamiento 1	0.371	0.689	$p > .05$	*ns*

El análisis revela que el Tratamiento 2 produce significativamente más biomasa seca en comparación con el Tratamiento 1, consolidando la superioridad estadística de dicha intervención.

---

8. Discusión y Conclusiones Generales

Discusión

Los datos proporcionan evidencia sobre la modulación del crecimiento vegetal mediante agentes exógenos. La inferioridad del Tratamiento 1 sugiere un ambiente subóptimo para el metabolismo basal de la planta. En contraste, el Tratamiento 2 logra elevar el techo productivo de la biomasa de manera homogénea. Entre las limitaciones destaca el tamaño de muestra ($n = 10$), el cual limita el poder estadístico en comparaciones cruzadas frente al control. Se recomienda transitar a Diseños de Bloques en etapas futuras.

Conclusiones

Con base en el rigor metodológico aplicado, se realizó un análisis de varianza de un factor para examinar el efecto del tratamiento en el peso seco de las plantas. Los resultados indicaron que existe un efecto significativo del tratamiento, $F(2, 27) = 4.85$, $p = .016$, η^2 = .26. El análisis post-hoc determinó específicamente que el Tratamiento 2 es estadísticamente superior al Tratamiento 1. Se concluye que el protocolo del Tratamiento 2 es el óptimo para una potencial escalabilidad agronómica.

Referencias Bibliográficas

1. American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7th ed.). https://doi.org/10.1037/0000165-000
2. Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Lawrence Erlbaum Associates.
3. Field, A. (2018). *Discovering statistics using IBM SPSS statistics* (5th ed.). SAGE Publications.
4. Montgomery, D. C. (2017). *Design and analysis of experiments* (9th ed.). Wiley.